



REDES NEURAIS ARTIFICIAIS
LISTA DE EXERCÍCIOS
PROFESSOR DR. HITALO NASCIMENTO

Nome: Larissa Vitória Vasconcelos Sousa

Matrícula: 519221

1. a) Falso. Na etapa de propagação para frente, os pesos da rede não são ajustados. Durante esse processo, a saída da rede é calculada com base nos pesos existentes e nas entradas fornecidas, sem modificar os pesos. A propagação para frente é responsável por transmitir as entradas até a camada de saída, enquanto as atualizações nos pesos ocorrem na fase de retropropagação, que faz parte do processo de treinamento da rede neural.

b) Verdadeiro. Em tarefas de classificação binária, é comum submeter a saída final de uma rede neural MLP a uma função de ativação, como a Sigmoide ou a ReLU, antes de compará-la com o valor alvo desejado.

2. a) Na aprendizagem supervisionada, o modelo passa por treinamento usando um conjunto de dados rotulado, no qual as entradas estão associadas a respostas conhecidas. O objetivo é capacitar o modelo a generalizar para novas entradas, gerando saídas corretas. Em contraste, na aprendizagem por reforço, um agente toma decisões sequenciais em um ambiente, recebendo sinais de reforço ou recompensas que indicam a qualidade das ações em relação ao objetivo final. A conexão entre esses dois paradigmas reside no fato de que, em ambos os casos, o sistema procura otimizar seu desempenho com base no feedback. Na aprendizagem supervisionada, o feedback é explicitamente fornecido pelos rótulos dos dados, enquanto na aprendizagem por reforço, o feedback é implicitamente incorporado na forma de recompensas.

b) O treinamento em aprendizado por reforço costuma ser mais demorado em comparação com o aprendizado supervisionado convencional. Isso decorre do fato de que, no aprendizado por reforço, o agente muitas vezes precisa explorar diversas ações antes de identificar uma política eficaz.

c) A aprendizagem por reforço encontra aplicação em contextos nos quais um agente precisa interagir dinamicamente com um ambiente para tomar decisões sequenciais. Isso é especialmente evidente em jogos como xadrez, Go e videogames, nos quais o agente toma decisões com base em ações passadas e recebe recompensas ou penalidades. Além disso, é amplamente utilizado na área de robótica para treinar robôs em tarefas complexas, como manipulação de objetos ou navegação em ambientes desconhecidos. Na área de sistemas de controle, a aprendizagem por reforço é empregada para otimizar o comportamento ao longo do tempo, visando objetivos específicos.

3. a) Descomplicação e Eficácia: A Estrutura A é caracterizada pela sua simplicidade, composta apenas por uma camada intermediária contendo 100 unidades. Isso pode acelerar e otimizar o processo de treinamento, especialmente quando lidamos com problemas relativamente simples que podem ser adequadamente modelados por uma função linear.

b) Ampliação da Capacidade de Representação: Ao incorporar uma camada intermediária com 10 unidades na Rede B, possibilita-se uma representação mais elaborada e complexa das



relações presentes nos dados. Essa camada extra contribui para a captura de padrões mais intrincados e não-lineares, sendo particularmente vantajosa em situações que envolvem desafios mais complexos.

4. A Rede Neural de Base Radial (RBFNN) utiliza funções de base radial em suas camadas ocultas e seu treinamento envolve a determinação de parâmetros, incluindo centros e pesos. Os centros podem ser obtidos não supervisionadamente, por exemplo, com o algoritmo K-means, agrupando entradas em clusters. Uma vez estabelecidos os centros, os pesos associados são determinados usando métodos de otimização como regressão linear. O treinamento pode ser aprimorado supervisionadamente, ajustando pesos finais para minimizar a diferença entre as saídas da rede e saídas desejadas, geralmente através de métodos como o gradiente descendente. Técnicas de regularização, como a de peso ou dropout, ajudam a evitar overfitting, especialmente com um grande número de funções de base radial. Otimizações globais, como algoritmos genéticos, podem ser aplicadas para ajustar os parâmetros, e a validação cruzada é útil para avaliar o desempenho da RBFNN e evitar overfitting. Essas abordagens abrangentes destacam a diversidade de métodos utilizados no treinamento eficaz de RBFNNs.

6.

$$\textcircled{6} \quad f(v) = \frac{1 - e^{-av}}{1 + e^{-av}}$$
$$f(v) = \frac{e^{av} - 1}{e^{av} + 1}$$
$$\frac{df}{dv} = \frac{(e^{av} + 1)(ae^{av}) - (e^{av} - 1)(ae^{av})}{(e^{av} + 1)^2}$$
$$\frac{df}{dv} = \frac{2ae^{av}}{(e^{av} + 1)^2} \quad \leadsto \quad \frac{df}{dv} = \frac{2a}{(e^{av} + 1)^2}$$
$$\frac{a}{2} (1 - f(v))^2 = \frac{a}{2} \left(1 - \left(\frac{1 - e^{-av}}{1 + e^{-av}} \right)^2 \right)$$

7. A Regra de Hebb e a Regra Delta representam abordagens distintas para a aprendizagem em redes neurais.



Regra de Hebb:

- Baseia-se no princípio de "células que disparam juntas, se ligam juntas", fortalecendo sinapses por atividade simultânea.
- Predominantemente aplicada em aprendizado não supervisionado, identificando padrões de ativação em tarefas de associação.
- Apresenta limitações em redes mais complexas.
- Fortalece pesos sinápticos entre neurônios ativados simultaneamente.
- Adequada para tarefas de associação em aprendizagem não supervisionada.

Regra Delta:

- Utiliza o princípio da minimização do erro, ajustando pesos para reduzir a diferença entre saídas desejadas e saídas reais.
- Associada à aprendizagem supervisionada, sendo empregada em tarefas como classificação e regressão.
- Destaca-se por sua escalabilidade e capacidade de adaptação a arquiteturas modernas de redes neurais.
- Utiliza o gradiente descendente para ajustar pesos eficazmente durante o treinamento da rede.
- Empregada em tarefas de classificação e regressão em aprendizagem supervisionada.